FIAP + alura

Pós Tech - Data Analisys
Turma 7DTAT
Tech Challenge #2 - Machine Learning and Time Series

Daniela Meneghello - RM: 356004

Maurício José de Lima - RM:358817

Pedro Vitor da Silva Pinto – RM: 358876

1. Descrição do Problema

- Imagine que você foi escalado para um time de investimentos e precisará realizar um modelo preditivo com dados da IBOVESPA (Bolsa de valores) para criar uma série temporal e prever diariamente o fechamento da base. Para isso, utilize a base de dados contida no site da Investing (https://br.investing.com/indices/bovespa-historical-data) e selecione o período "diário", com o intervalo de tempo que achar adequado.
- Você precisará demonstrar para o time de investimentos:
    1. O modelo com o storytelling, desde a captura do dado até a entrega do modelo;
    2. Justificar a técnica utilizada;
    3. Atingir uma acuracidade adequada (acima de 70%).

2. Análise Exploratória dos Dados

- Realizamos o download do arquivo .csv do site Investing, conforme informado, contendo os dados de fechamento da Ibovespa ente 2005 e 2024.

```
# Leitura do arquivo ** mostrar de onde veio o dado - 2005 até final de 2024

df = pd.read_csv('https://raw.githubusercontent.com/jdlmauricio/techalleg_fase_2/refs/heads/main/Dados%20Hist%C3%B3ricos%20-%20Ibovespa.csv')
```

	Data	Último	Abertura	Máxima	Mínima	Vol.	Var%
0	30.12.2024	120.283	120.267	121.050	120.158	8,90M	0,01%
1	27.12.2024	120.269	121.078	121.609	120.252	8,94M	-0,67%
2	26.12.2024	121.078	120.767	121.612	120.428	8,34M	0,26%
3	23.12.2024	120.767	122.105	122.105	120.617	9,95M	-1,09%
4	20.12.2024	122.102	121.183	122.209	120.700	18,13M	0,75%

2. Análise Exploratória dos Dados

- Realizamos então a transformação dos dados, como exclusão de colunas desnecessárias, renomeação de colunas, e conversões de tipos de dados, para os padrões que utilizaremos em nossas análises:
- Criamos a série completa de dados e preenchemos valores ausentes com o valor do dia anterior:

```
# Remove colunas desnecessárias ***
df = df.drop(columns=['Abertura', 'Máxima', 'Mínima', 'Vol.', 'Var%'])
# Renomeia colunas
df = df.rename(columns={'Data': 'ds', 'Último': 'y'})
# Converte coluna de data
df['ds'] = pd.to_datetime(df['ds'], format='%d.%m.%Y')
# Colocando a data como index
df = df.set_index('ds')
```

```
# Criando uma série completa com finais de semana e feriados ***
datas_completas = pd.date_range(start=df.index.min(), end=df.index.max(), freq='D')
df = df.reindex(datas_completas)
```

```
## Preenchendo valores ausentes com o último valor conhecido (forward-fill) ***
df['y'] = df['y'].fillna(method='ffill')
```

2. Análise Exploratória dos Dados

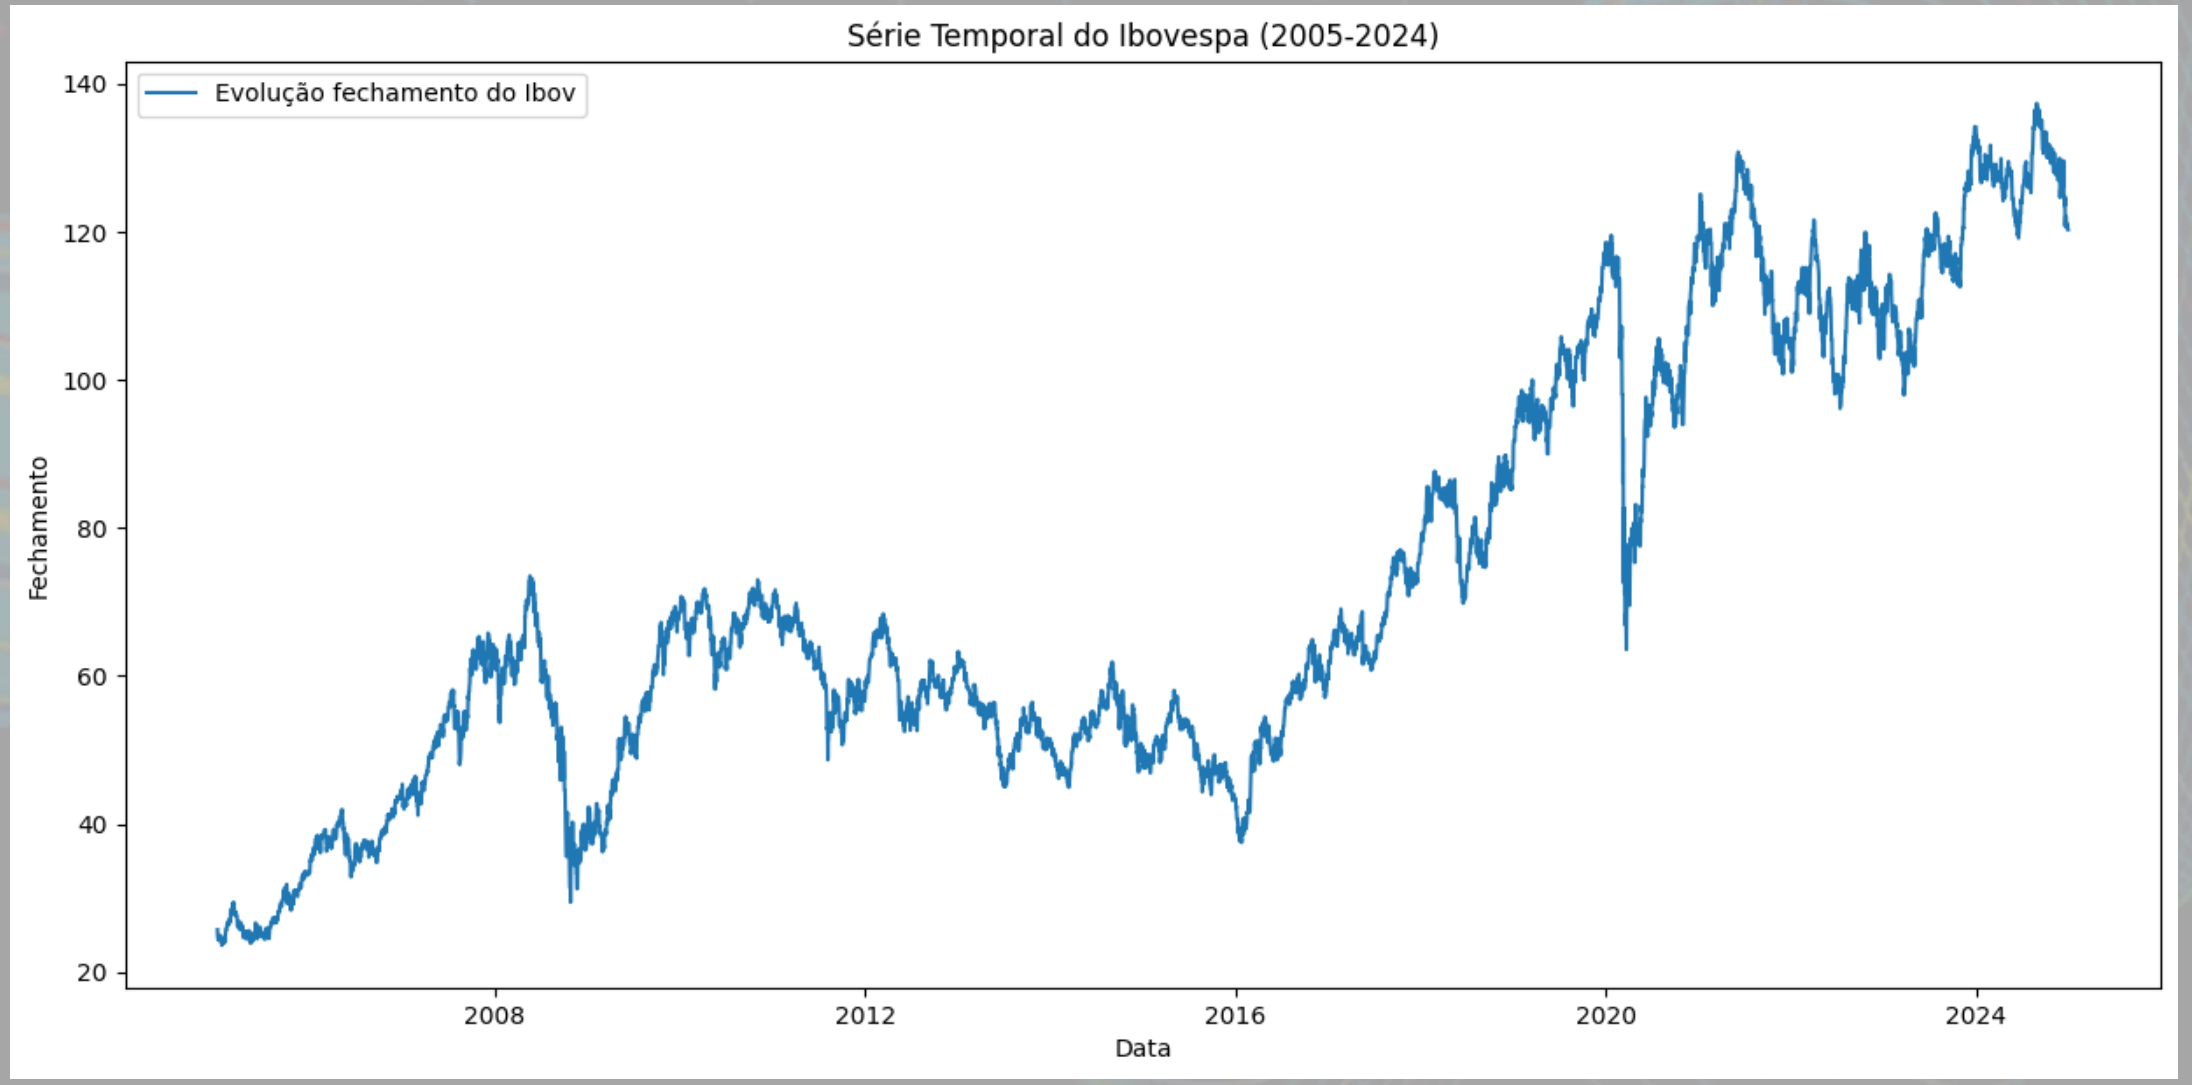

2. Análise Exploratória dos Dados

Linha temporal com fatos relevantes

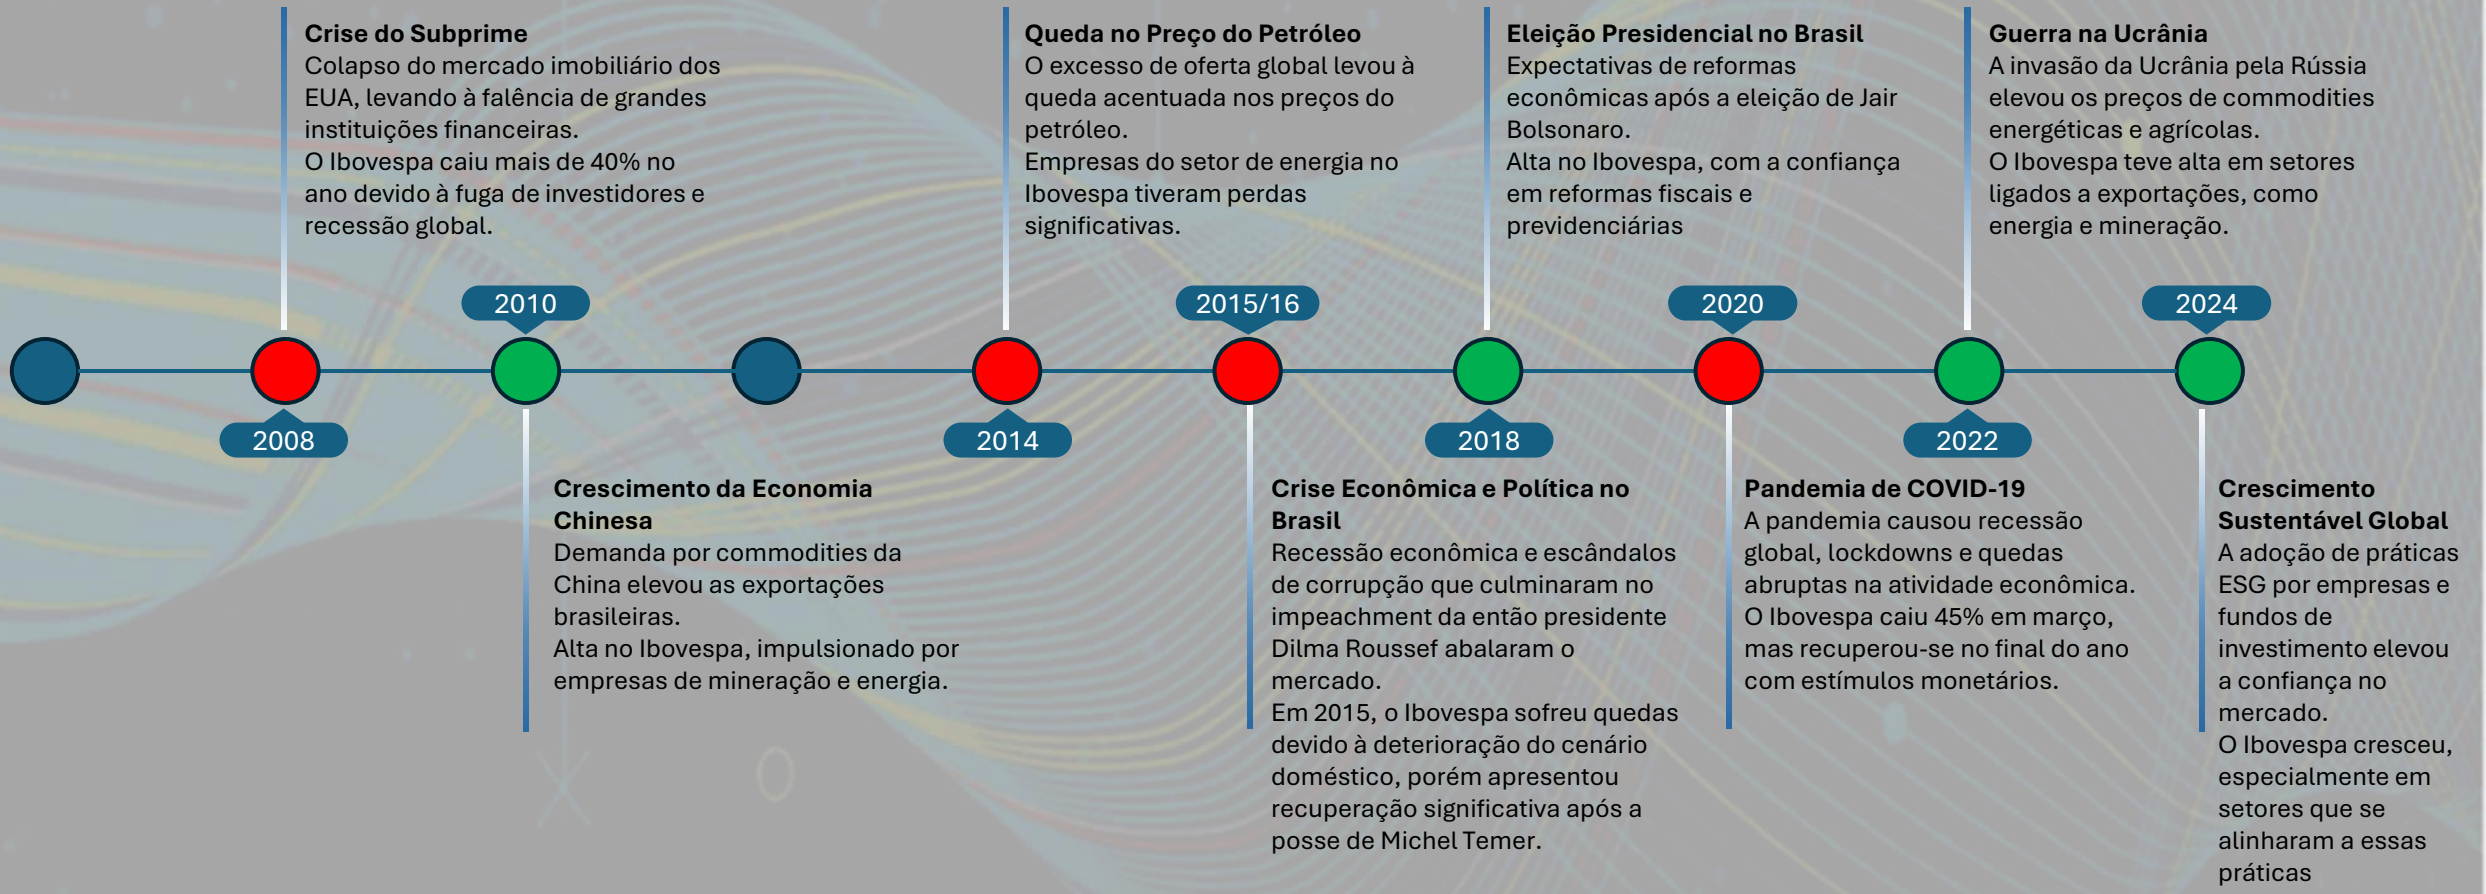

3. Decomposição da Série Temporal

Decomposição aditiva

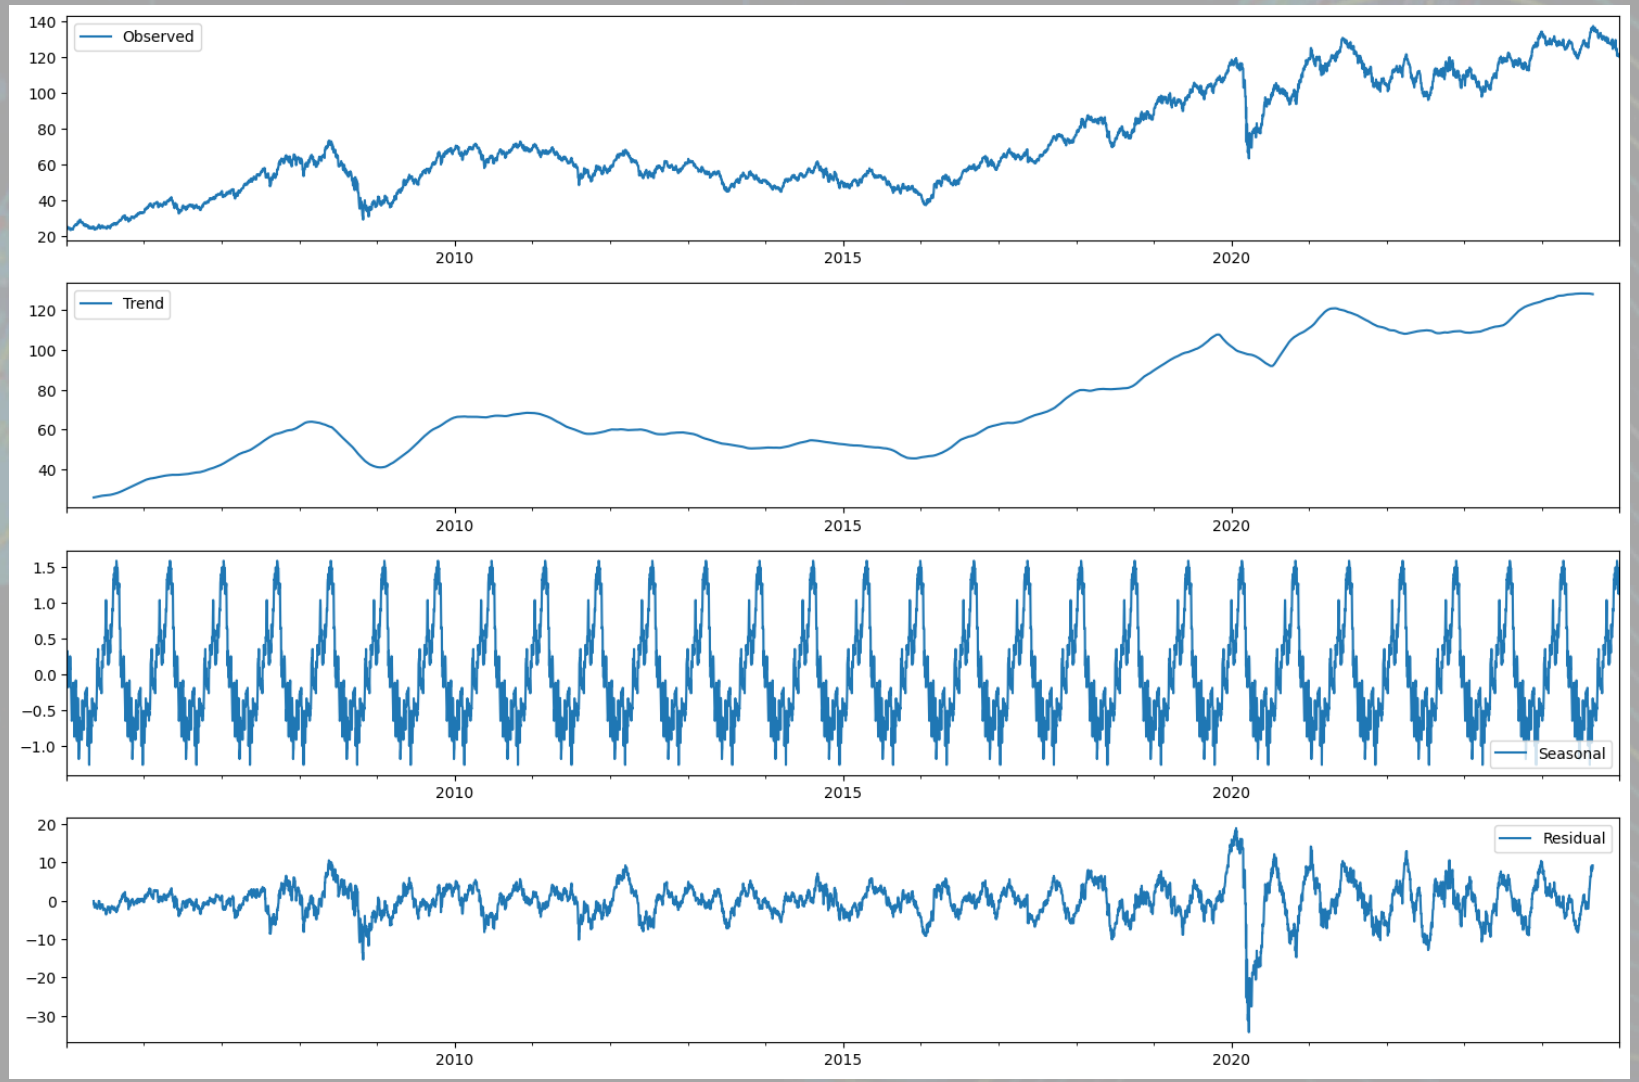

4. Modelos

- Inicialmente, realizamos a separação da base de treino e validação;
- Definimos para 15 dias o período de previsão.

```
# Definição de período de Treino e validação ***

treino = df.loc[(df['ds'] >= '2021-01-01') & (df['ds'] < '2024-01-01')]

valid = df.loc[(df['ds'] >= '2024-01-01') & (df['ds'] < '2024-01-16')]

h = valid['ds'].nunique() # Quantidade de dias a serem previstos
```

h
15

4. Modelos

Naive

- Realizamos a previsão dos 15 primeiros dias de 2024, utilizando o período de treino para o modelo:

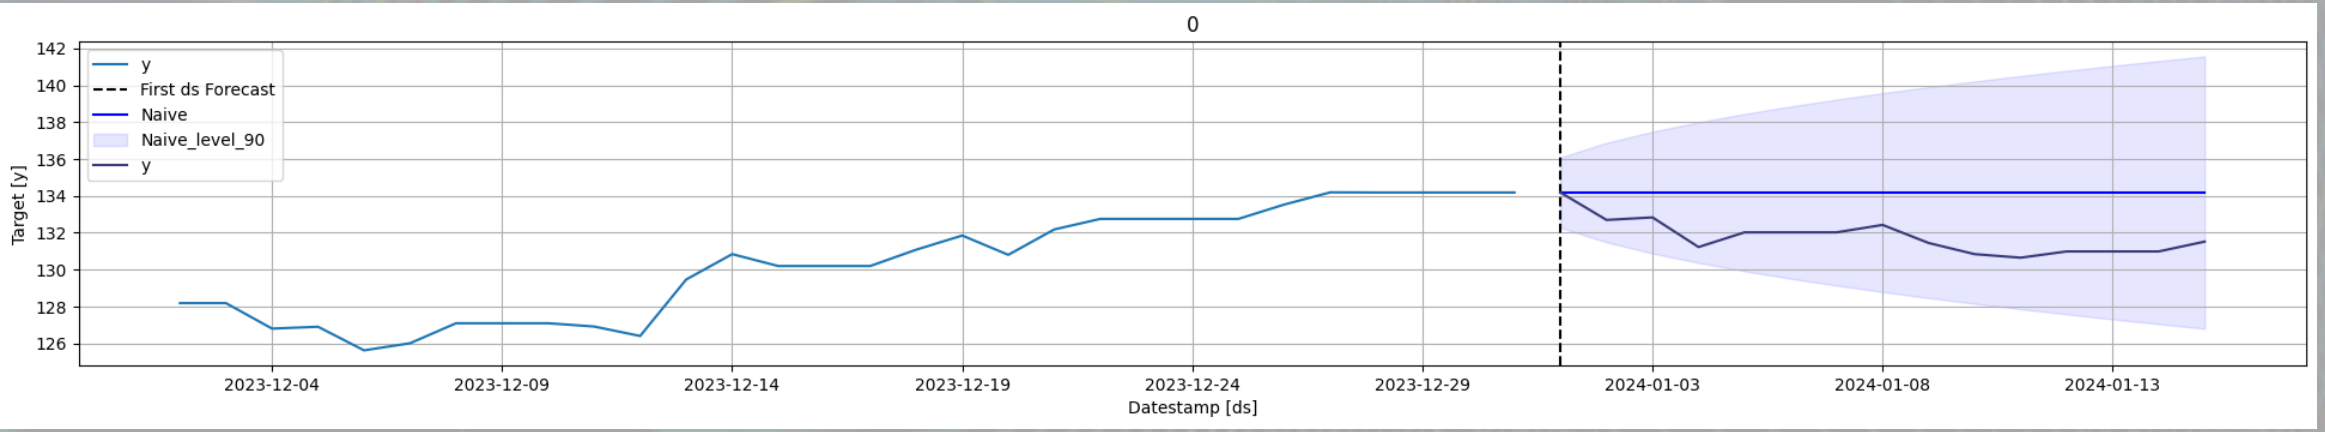


```
MAE Naive Baseline: 2.394331217447918
rmse Naive Baseline: 2.567096227697468
MAPE Naive Baseline: 0.018217591255696986
WMAPE Naive Baseline: 1.82%
MSE Naive Baseline: 6.589983042258569
```

MAE (Mean Absolute Error: Fornece o erro médio absoluto.
RMSE (Root Mean Squared Error): Destaca grandes erros; útil para entender discrepâncias maiores.
MAPE (Mean Absolute Percentage Error): Erro relativo em porcentagem, ajuda na comparação de escalas diferentes.
WMAPE (Weighted Mean Absolute Percentage Error): Corrige distorções do MAPE para séries heterogêneas.
MSE(Mean Squared Error): Ideal para análises que priorizam grandes desvios, mas pode ser difícil de interpretar devido à unidade ao quadrado.

4. Modelos

Seasonal Window Average

- Realizamos a previsão dos 15 primeiros dias de 2024, utilizando o período de treino para o modelo:

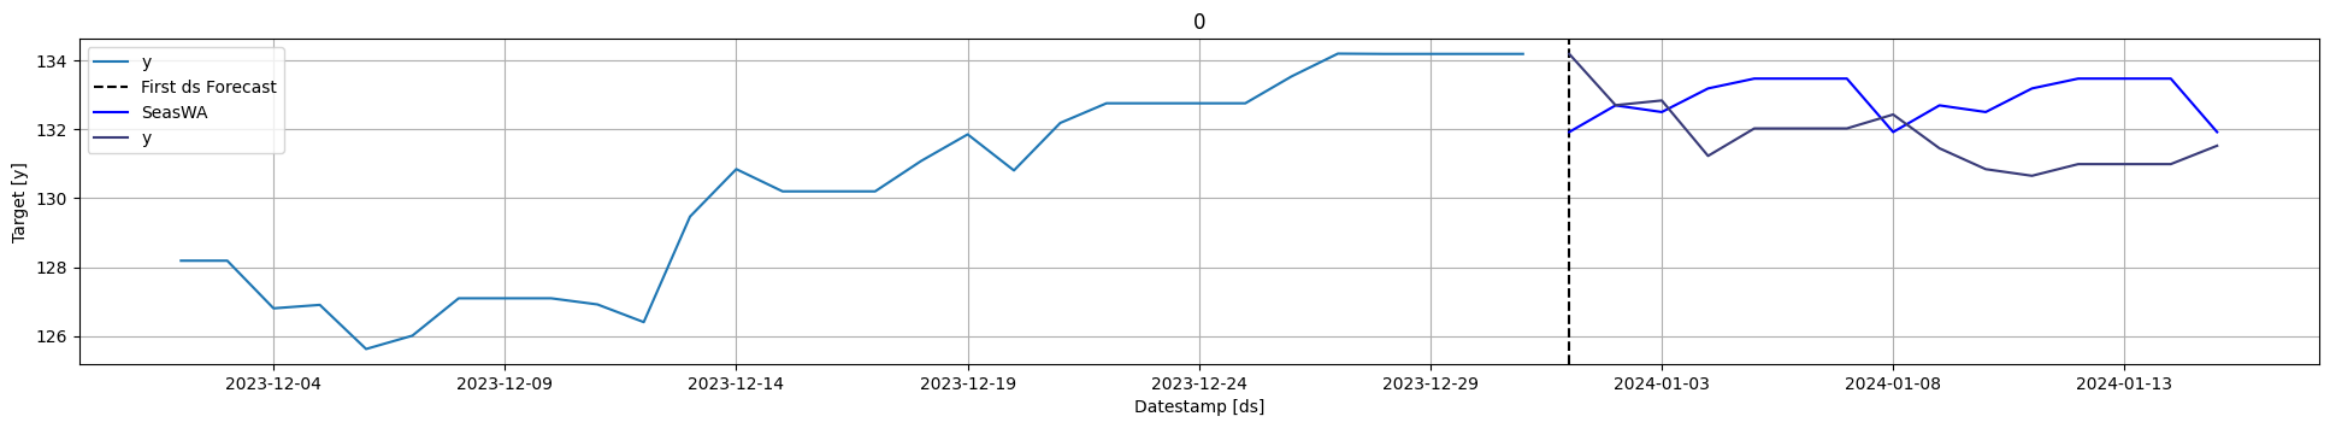


```
MAE swa : 1.5125644287109385
rmse swa : 1.7312619708939774
MAPE swa : 0.011496800549552691
WMAPE swa : 1.15%
MSE swa : 2.997268011863699
```

MAE (Mean Absolute Error: Indica o erro absoluto médio do modelo sazonal.
RMSE (Root Mean Squared Error): Destaca grandes erros entre as previsões e os valores reais.
MAPE (Mean Absolute Percentage Error): Mede a precisão relativa, sendo sensível a valores pequenos.
WMAPE (Weighted Mean Absolute Percentage Error): Avalia o erro proporcional com peso, corrigindo distorções do MAPE.
MSE(Mean Squared Error): Útil para analisar a variabilidade dos erros, mas é sensível a outliers.

4. Modelos

Sarima

- Para aplicação do modelo Sarima, realizamos inicialmente a aplicação da derivação na série temporal e o teste de Dickey – Fuller Aumentado (ADF)

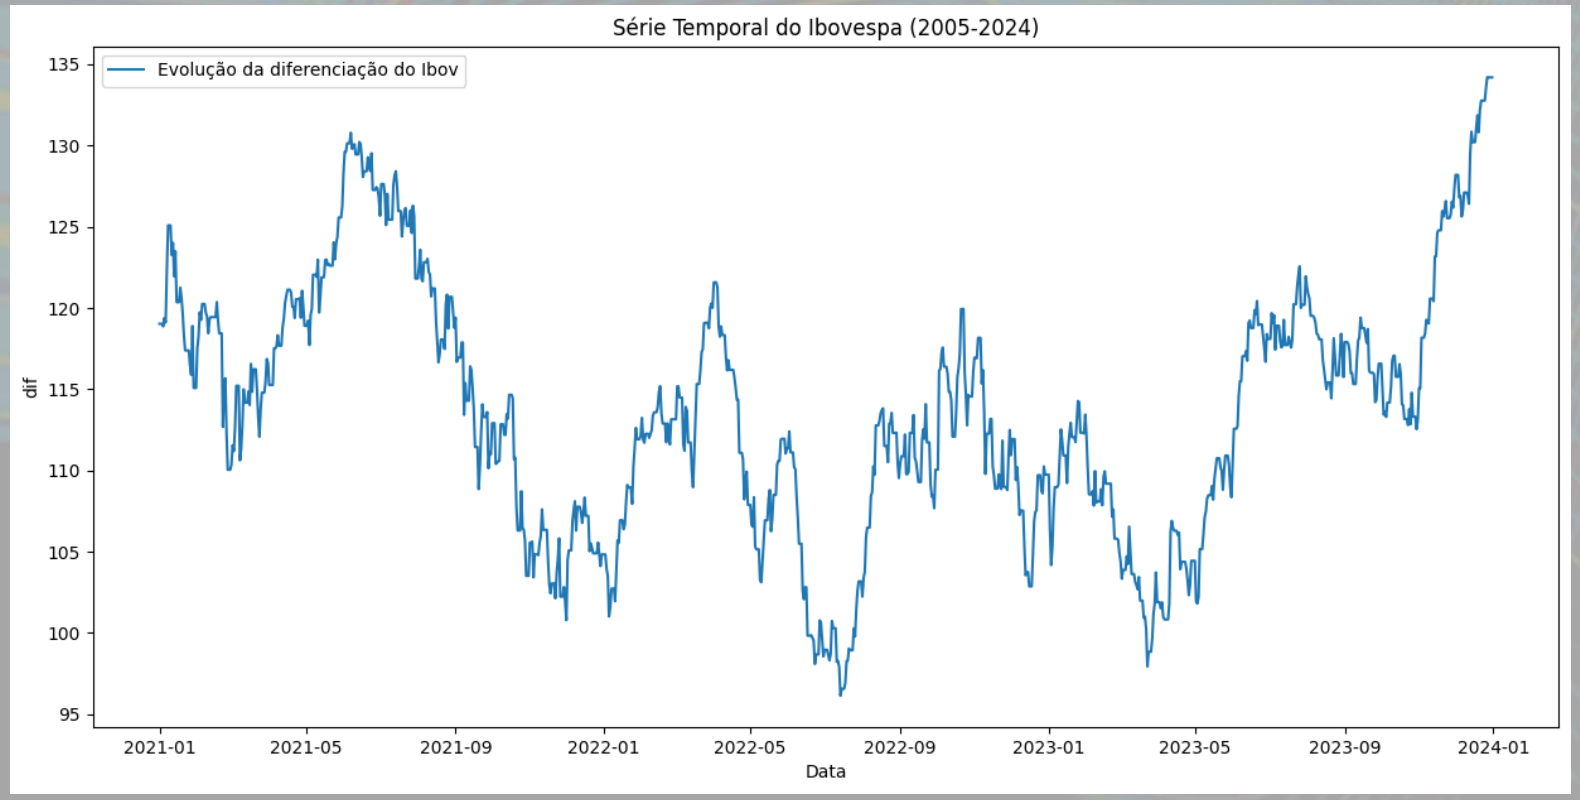


```
Estatística ADF: -1.8202703522041512
Valor-p: 3.704454724514131e-01
Valor Crítico 1%: -3.436341508283391
Valor Crítico 5%: -2.864185524365606
Valor Crítico 10%: -2.5681785627437677
A série não é estacionária.
```

4. Modelos

Sarima

- Aplicamos o método da Diferenciação de Primeira Ordem e novamente o teste ADF obtendo o resultado de que a série é estacionária:

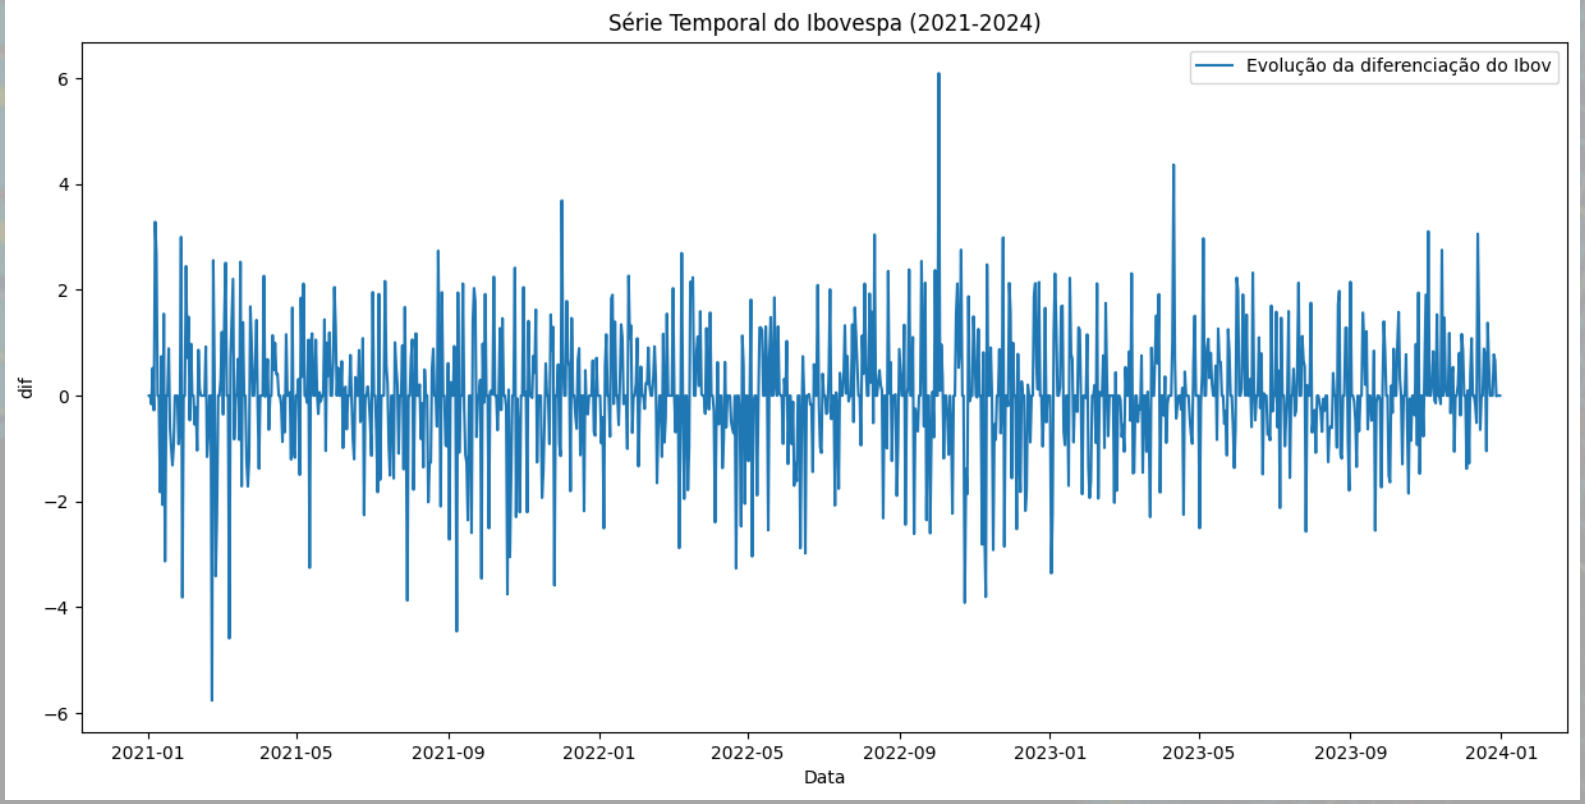


```
Estatística ADF: -34.056002586118545
Valor-p: 0.000000000000000e+00
Valor Crítico 1%: -3.4363470029475525
Valor Crítico 5%: -2.864187948086107
Valor Crítico 10%: -2.568179853605536
A série é estacionária.
```

4. Modelos

Sarima

- Realizamos a identificação dos Parâmetros para o Modelo – ACF e PACF
- ACF (Autocorrelation Function): Mede a correlação entre a série e suas defasagens, considerando efeitos diretos e indiretos. Ajuda a identificar o parâmetro MA (q) em modelos SARIMA.
- PACF (Partial Autocorrelation Function): Mede a correlação direta entre a série e uma defasagem específica, eliminando influências intermediárias. Ajuda a definir o parâmetro AR (p) no modelo.

4. Modelos

Sarima

- ACF e PACF

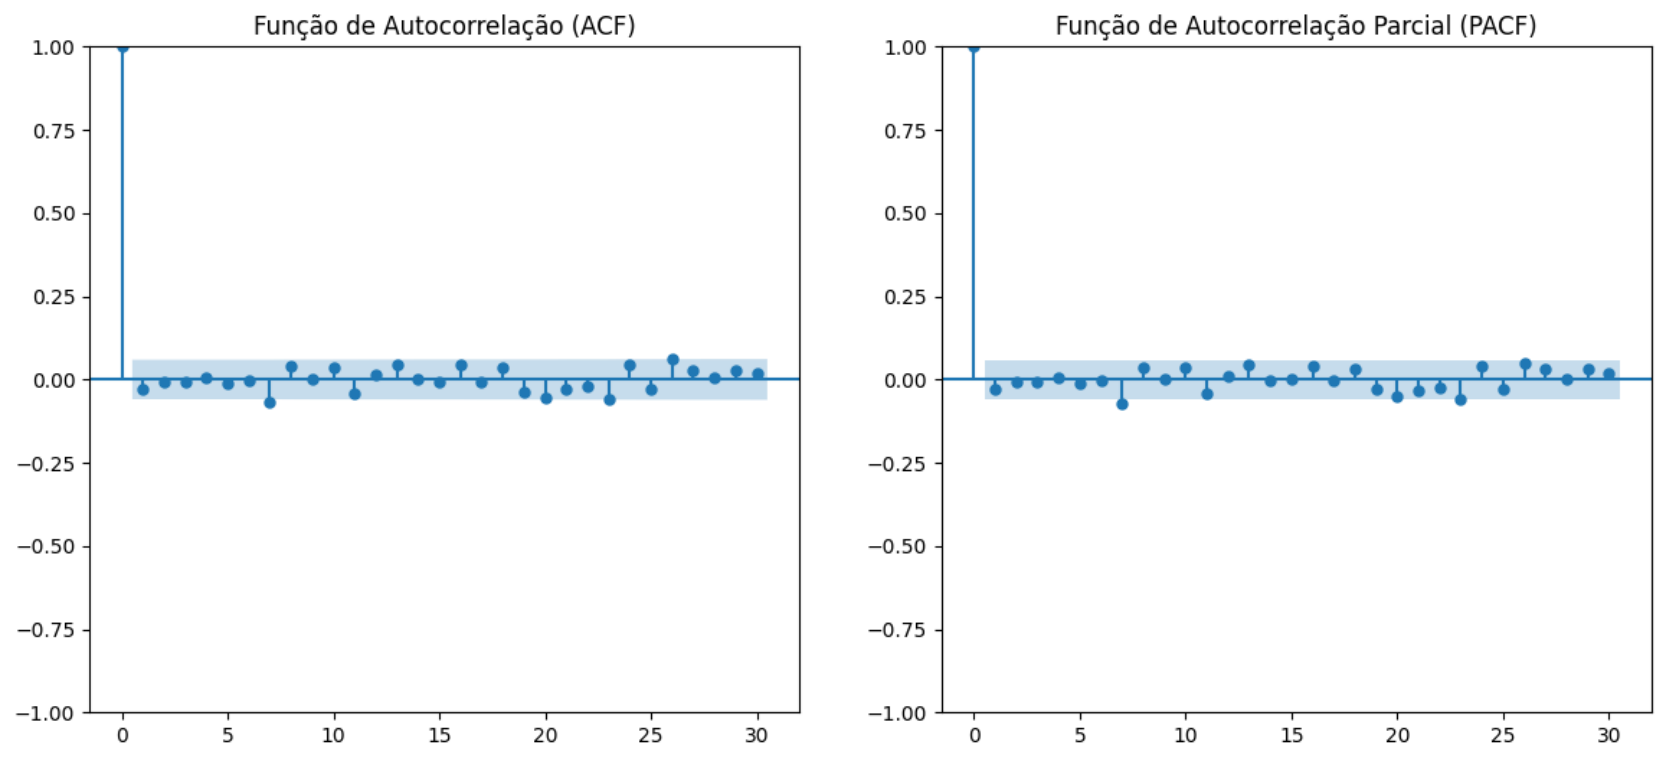


```
p = 1 # compentente AR ***
d = 1 # Componente I
q = 1 # Componente MA
```

4. Modelos

Sarima

- Para a aplicação do modelo Sarima, assumimos uma sazonalidade de 21 dias:

SARIMAX Results

Dep. Variable:	dif	No. Observations:	1094
Model:	SARIMAX(1, 1, 1)x(1, 1, 1, 21)	Log Likelihood	-1725.821
Date:	Sun, 19 Jan 2025	AIC	3461.643
Time:	15:13:52	BIC	3486.529
Sample:	01-02-2021	HQIC	3471.069
	- 12-31-2023		
Covariance Type:	opg		

	coef	std err	z	P>|z|	[0.025	0.975]
ar.L1	-0.0330	0.032	-1.041	0.298	-0.095	0.029
ma.L1	-0.9999	0.288	-3.474	0.001	-1.564	-0.436
ar.S.L21	-0.0355	0.025	-1.438	0.150	-0.084	0.013
ma.S.L21	-0.9999	6.675	-0.150	0.881	-14.082	12.082
sigma2	1.3386	8.939	0.150	0.881	-16.181	18.859

Ljung-Box (L1) (Q):	0.00	Jarque-Bera (JB):	223.50
Prob(Q):	0.96	Prob(JB):	0.00
Heteroskedasticity (H):	0.63	Skew:	-0.13
Prob(H) (two-sided):	0.00	Kurtosis:	5.22

4. Modelos

Sarima

- Realizamos a previsão dos 15 primeiros dias de 2024 :

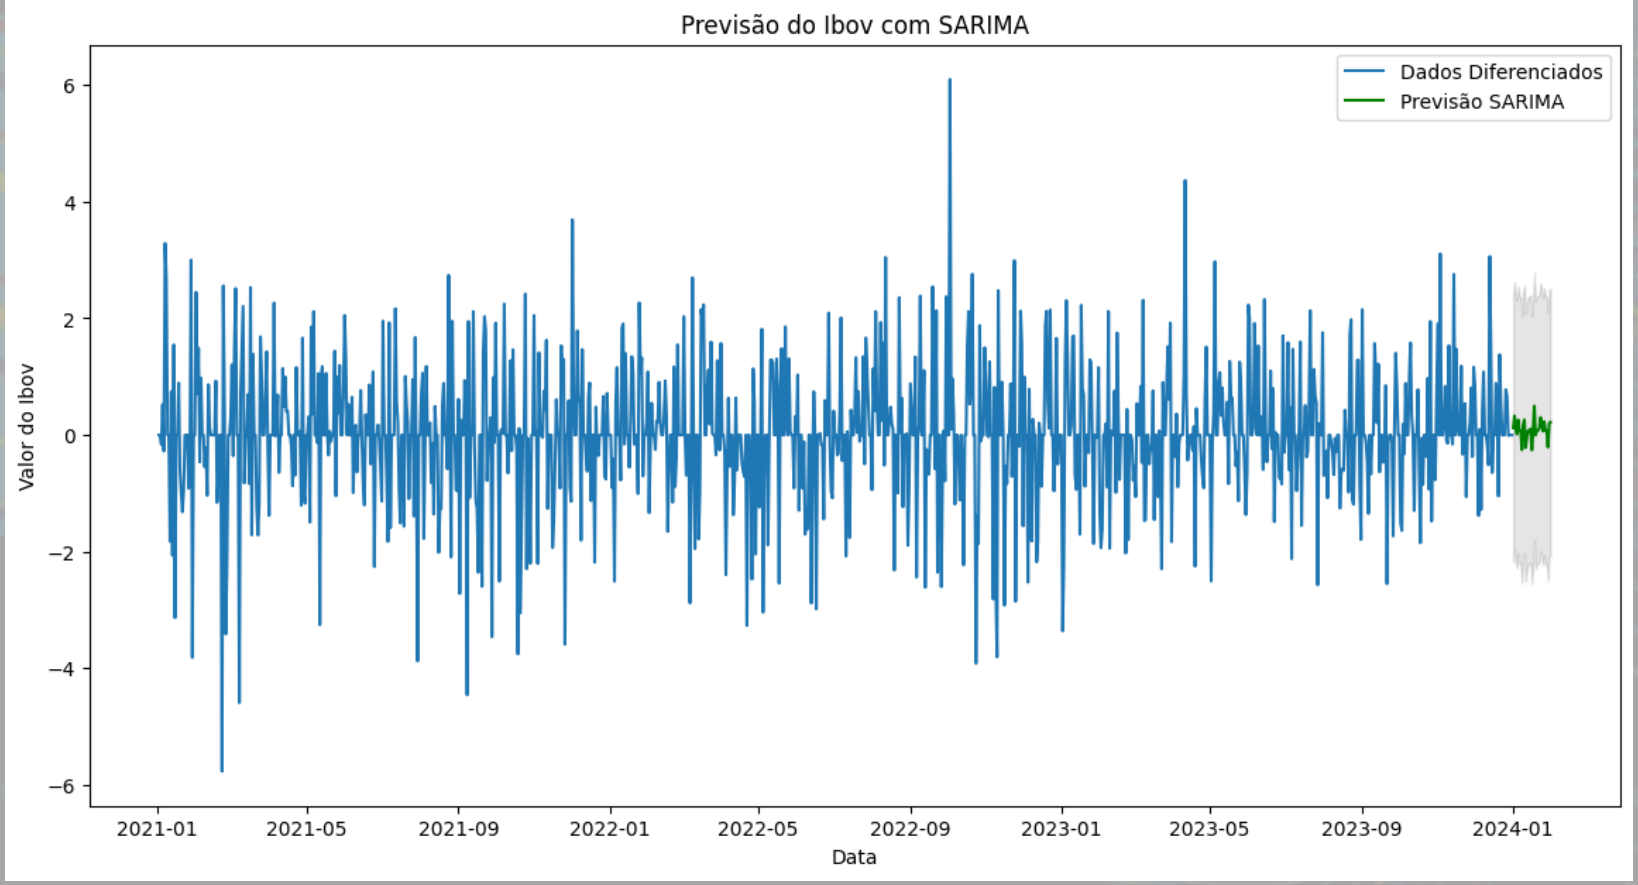


```
MAE sarima : 131.71240284684617
rmse sarima : 131.71552256967968
MAPE sarima : 0.999407811846199
MSE sarima : 17348.978885803794
R² sarima : -20239.00864716429
```

4. Modelos

Prophet

- Realizamos a previsão dos 15 primeiros dias de 2024, utilizando o período de treino entre 17 e 31 de dezembro de 2024 para o modelo:

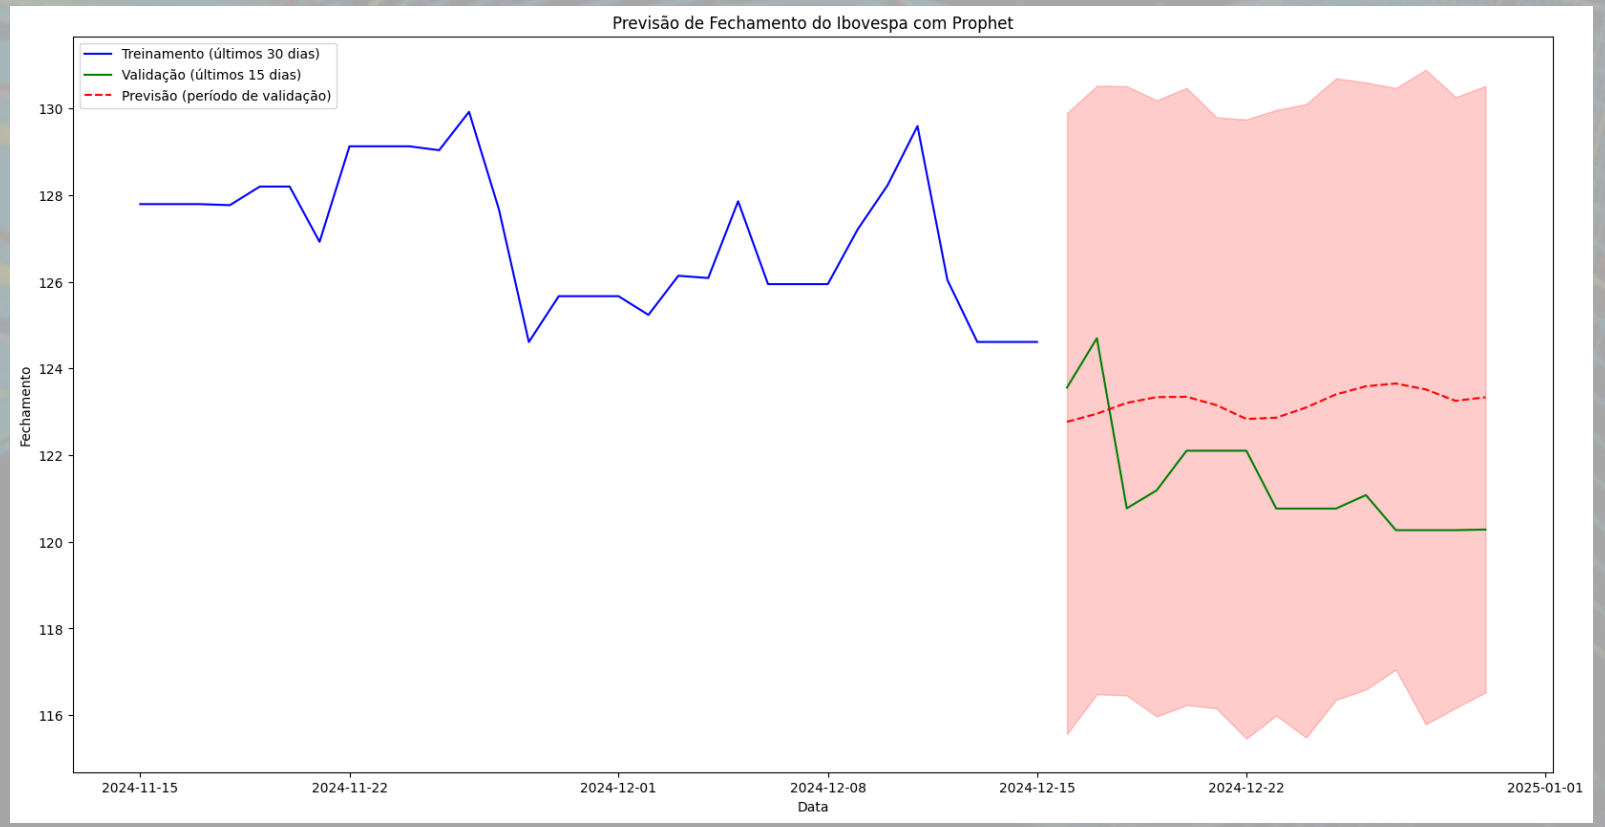


```
MAE: 2.159287331731115
RMSE: 2.319523116710507
MAPE: 0.02%
WMAPE para os últimos 15 dias: 0.01778661970472524
MSE: 5.380187488954423
```

8. Conclusão

- Durante a execução do Tech Challenge, realizamos treinos e testes com os modelos Naive, Seasonal Window Average, Sarima e Prophet;
- Realizando uma comparação entre os modelos, observamos os seguintes resultados:

Métrica	Naive	SWA	SARIMA	Prophet
MAE	23.943	15.126	1.317.124	21.593
RMSE	25.671	17.313	1.315.155	23.195
MAPE	1.82%	1.15%	99.94%	0.02%
WMAPE	1.82%	1.15%	-	1.78%
MSE	65.899	29.973	173.489.789	53.802
R^2	-66.881	-24.967	-202.390.086	-23.836

8. Conclusão

- Observações sobre os resultados:
  - O **modelo Seasonal Window Average** se destacou como o melhor entre os analisados. Ele teve os menores valores de erro absoluto (MAE: 1.5126) e quadrático médio (RMSE: 1.7313), além de um WMAPE de 1.15%, o que demonstra consistência nos resultados.
    Apesar de o R^2 ser negativo (-2.4967), esse modelo ainda apresenta um desempenho superior ao dos outros.
  - O **Modelo Prophet** chamou a atenção pelo menor MAPE (0.02%), mas seu desempenho geral em outras métricas, como MAE, RMSE e R^2, ficou atrás, tornando-o menos confiável como uma escolha principal, tornando –o uma escolha secundária.
  - Por outro lado, o **Modelo Sarima** teve resultados ruins em todas as métricas avaliadas, sugerindo que ele não foi bem ajustado aos dados.

8. Conclusão

- Conclusão final: o **Modelo Seasonal Window Average** é o mais equilibrado e confiável no geral, sendo a melhor opção para a maioria dos cenários, uma vez que combina baixos erros e maior consistência dos resultados.
  O modelo Prophet pode ser considerado em situações mais específicas, como por exemplo, para análises mais voltadas ao WMAPE recente.